최적화 전후 Benchmark 보고서

엔진 모형 검사 프로젝트 | 평가영역 5: 경량화·성능 Benchmark | v1.1

프로세스 메모리 약 49% 감소 · 고정 조건 검출 결과 유지

현재 운영 중인 M1·M2 를 동일 Jetson 에서 원본 PyTorch FP32 와 비교했다. 학습 모델의 ONNX·TensorRT 변환과 장치 실행을 연결하고, 속도·메모리·검출 성능을 함께 측정해 엣지 배포의 성과를 확인했다.

원본 사진	비교 조건	본 측정 실행	지연시간 원본
E03 72 장	M1/M2 × PT/TRT	12 회 (조건별 3 회)	4,320 개 구간

핵심 성과와 전후 비교

검토 항목	M1 부품 검출	M2 엔진 전체 검출
프로세스 RSS 관측 최대	**1,250.5 → 636.9 MiB 약 49.1% 감소**	**1,263.8 → 649.7 MiB 약 48.6% 감소**
고정 조건 TP / FP / FN	PT·TRT 모두 192 / 0 / 0	PT·TRT 모두 72 / 0 / 0
mAP50-95 (0~1)	0.639911 → 0.640873	0.836717 → 0.836629
평균 지연시간	29.313 → 29.022 ms 약 0.99% 감소	29.480 → 30.266 ms 약 2.67% 증가
처리량	34.06 → 34.41 image/s	33.87 → 33.00 image/s

> 핵심 성과는 실행 메모리 효율이다. TensorRT 의 RSS 관측 최대는 48.6~49.1% 감소했고, E03 고정 조건의 TP·FP·FN 은 두 백엔드에서 같았다. 평균 처리 시간은 모델별 약 30ms 였다. 속도 변화는 M1 약 1% 감소·M2 약 2.7% 증가로, 가속보다 메모리 절감 효과가 뚜렷했다.

평가항목과 실증 근거

평가기준	보고서 위치	대표 원자료
ONNX·TensorRT 변환	2 쪽, 15 쪽	provenance/ · model_hashes.json
동일 조건의 비교	3-4 쪽	protocol.json · environment_effective.json
FPS·Latency·메모리·정확도	5-11 쪽	각 raw/summary CSV · accuracy.json
검증 과정·성과·개선 방향	12-14 쪽	측정 보완·복귀·후속 계획

근거: [R0] 평가표 1 쪽 영역 5. [B01-B06] 측정 원문. 화살표는 PT → TensorRT. 지연시간은 전처리·후처리 포함; RSS 는 본 측정 구간의 100ms 샘플 관측 최대. P/R 기준은 confidence 0.25, 정답 IoU 0.50.

01 비교 모델과 변환 이력

동일 학습 가중치의 변환·배포 이력과 실제 실행 파일을 연결해, 현재 운영 모델을 대상으로 비교했다.

항목	M1	M2
역할 / 클래스	부품 검출 / gray_pipe, exhaust_top, symbol_module	엔진 전체 검출 / product_envelope
운영 패키지	dynamic_parts_005	envelope_v007_fp16
가중치 계통	CFA8507_original_PT_fp16_head32	envelope_v004_E01_E02_144
원본 PT 파일 크기	5.20 MiB (5,456,154 B)	5.20 MiB (5,449,562 B)
ONNX 파일 크기	10.08 MiB (10,566,638 B)	10.08 MiB (10,564,980 B)
운영 plan 파일 크기	9.62 MiB (10,092,164 B)	12.93 MiB (13,556,092 B)
입력 / 출력	[1,3,640,640] / [1,7,8400]	[1,3,640,640] / [1,5,8400]
TRT 정밀도 정책	FP16 + head FP32 빌드 기록의 FP32 지정 레이어 77 개	FP16 + backbone FP32 빌드 기록의 FP32 지정 레이어 208 개

변환 단계별 기록

단계	확인된 설정과 증빙
PT → ONNX	Ultralytics YOLO.export 8.4.146; imgsz 640, batch 1, dynamic=False, half=False, nms=False, simplify=False, opset=12. 각 export.json 에 원본 PT 및 ONNX 해시를 보존했다.
ONNX → TensorRT	TensorRT 10.3.0 Builder API; workspace 1 GiB, optimization_level=3, max_aux_streams=0, TF32=False, precision_constraints=OBEY. 입력·출력은 float32 이다.
운영 파일 연결	export → build_manifest → 제품 manifest → 실제 장치 파일 관측의 SHA-256 을 연결했다. 본 측정 run.json 에도 실행한 PT 또는 plan 해시가 기록된다. 전체 해시는 15 쪽에 기재했다.

원본 PT 에도 eval·fuse·inference_mode 를 적용하고, TensorRT 는 배포된 native .plan 을 직접 실행했다. 양쪽 모두 실제 추론 경로를 사용해 학습 모드나 불필요한 작업이 비교에 섞이지 않도록 했다.

> 정밀도 구성: M1 은 FP16+head FP32, M2 는 FP16+backbone FP32 다. 실행 메모리 감소는 이 혼합정밀도 운영 모델에서 확인한 결과다. plan 파일 크기는 PT 보다 크며, 파일 용량과 실행 중 RSS 는 구분한다. 빌드 당시 parity 기록과 이번 비교 시험도 각각 보존했다.

근거: [B02] protocol.json; [B08] provenance/M1·M2/{export,build_manifest,manifest}.json; model_hash_verification.json. 레이어 수는 빌드 설정 목록 수이며 실행 레이어별 프로파일링 결과가 아니다.

02 장치와 실행 환경

측정일 2026-10-19 | 채택 프로토콜 attempt002 | 기록된 실제 환경 기준

구분	측정 조건
장치	jetson-07 / NVIDIA Jetson Orin Nano Engineering Reference Developer Kit Super / aarch64
운영 릴리스	engine-integrated-32c484ac6aeb07f1
운영체제 / L4T	Ubuntu 22.04 / L4T 36.4.7
Python / GPU 프레임워크	Python 3.10.12 / PyTorch 2.8.0 / CUDA 12.6 / TensorRT 10.3.0
평가·영상 라이브러리	Ultralytics 8.4.118 / NumPy 1.26.4 / OpenCV 5.0.0
전력 모드	기존 25W mode 1 유지. 전력 모드·클록 고정 설정을 변경하지 않음.
메모리 / 시스템 부하	GNOME 데스크톱은 유지. 비교하는 ML 백엔드는 순차적으로 별도 프로세스에서 적재.
입력 처리	OpenCV 스레드 1; PT torch 스레드 1; 디스크 읽기·PNG 디코딩 후 메모리에 원본 72 장 준비.
PT 수치 설정	float32 파라미터, AMP OFF, matmul TF32 OFF, cuDNN TF32 OFF, cuDNN benchmark=False
장비 영향 통제	운영 검사 서비스를 일시 정지하고 경쟁 Python/CUDA 점유자를 점검한 후 측정. PLC 운전·신규 촬영 없음.

기존 운영 환경을 활용한 실행 구성

사전 점검에서 확인한 NumPy 2.2.6 과 PyTorch 간 호환 문제는 기존 NumPy 1.26.4 overlay 재사용으로 해소했다. 환경을 재설치하지 않고 운영에 사용하던 호환 경로로 측정했으며, 유효 환경과 초기 점검 기록을 함께 남겼다.

재사용 경로: /home/jetson/oned_device_bench/env_candidates/numpy_compat_001/overlay

환경 기록과 비교 범위

L4T·CUDA·TensorRT 등 실제 실행 버전을 기록했다. nvidia-jetpack 메타 패키지는 미설치였고 jetson_clocks --show 는 권한 제한이 있어, 동작 중 온도·클록·사용률은 tegrastats 원문으로 보완했다.

> 비교는 동일 장치·25W 설정에서 백엔드를 순차 실행한 조건이다. GNOME 부하와 동적 클록은 유지했으며, 반복별 변동도 결과표에 함께 제시했다.

근거: [B03] environment.json, environment_effective.json, telemetry_raw.jsonl; [B02] protocol.json; [B09] protocol_revisions/000_preflight_before_overlay.json 및 초기 adapter 실패 기록.

03 정상·결품 입력과 반복 측정 설계

정상과 다섯 결품 상태를 각 12 장씩 구성한 E03 전체 72 장으로 비교했다.

촬영 상태	사진 수	M1 정답 박스	M2 정답 박스
정상	12	48	12
왼쪽 파이프 결품	12	36	12
오른쪽 파이프 결품	12	36	12
배기 부품 결품	12	36	12
문양 부품 결품	12	36	12
대상 부품 전체 결품	12	0	12
합계	72	192	72

E03 D145-D216, 원본 1280×720 을 공통 letterbox 로 640×640 에 맞췄다. 내부 영상은 640×360, 위·아래 padding 은 각각 140 픽셀이다. padding 값 114, BGR→RGB, /255, float32 를 적용하며 crop·증강은 하지 않았다. M1·M2 의 정답 라벨은 별도다.

실행 수와 순서

항목	고정 내용
본 측정	4 조건 × 새 프로세스 3 회 × 360 회 = 4,320 구간. 조건당 1,080 구간.
각 프로세스	모델 로드 → 첫 호출 별도 기록 → 예열 50 회 → 72 장 5 회 순환 측정. 프로세스 사이 5 초 대기.
순서	반복 1·3: M1 PT→TRT, M2 PT→TRT. 반복 2: M1 TRT→PT, M2 TRT→PT.
정확도	조건별 첫 반복에서 72 장을 추가 추론. 한 raw 출력을 고정 cutoff 와 mAP 경로에 각각 적용.
중단·배제	이상치 임의 삭제 없음. 최초 실패 시도는 attempt001/에 별도 보존하고, 수정 후 12 회를 모두 새로 수행.

시간의 시작과 끝

> 측정 포함: 메모리의 원본 → 전처리 → GPU 추론 완료 → CPU 출력 → NMS·역좌표 변환 완료.
> 측정 제외: 파일 읽기, PNG 디코딩, 모델 로드, 첫 호출, 예열, 결과 그림·로그 파일 저장.

개별 지연은 perf_counter_ns 의 차이로 계산하며, PT 는 CUDA 동기화, TensorRT 는 native 실행 스트림과 장치→호스트 전송 완료를 확인한다. 처리량은 완료 이미지 수 ÷ 측정 루프의 실제 경과시간이다. 루프의 작은 메모리 기록 비용은 포함하므로 1/평균지연과 완전히 같지는 않다.

근거: [B02] protocol.json; [B04] input_manifest.csv, ground_truth.json; [B05] latency_raw.csv 및 run.json. 전체 대상 결품은 엔진 몸체를 유지한 부품 결품 상태다.

04 실행 메모리 효율: RSS 약 49% 감소

동일 E03 입력의 모델별 실행에서 TensorRT 의 프로세스 RSS 관측 최대가 약 절반으로 낮아졌다.

조건	RSS 관측 최대 MiB	기준 대비 RSS 최대 증가 MiB	시스템 사용량 추정 관측 최대 MiB
M1 PT	1,250.5	620.0	3,051.4
M1 TRT	636.9	301.9	2,683.6
M2 PT	1,263.8	629.1	3,072.6
M2 TRT	649.7	314.6	2,683.1

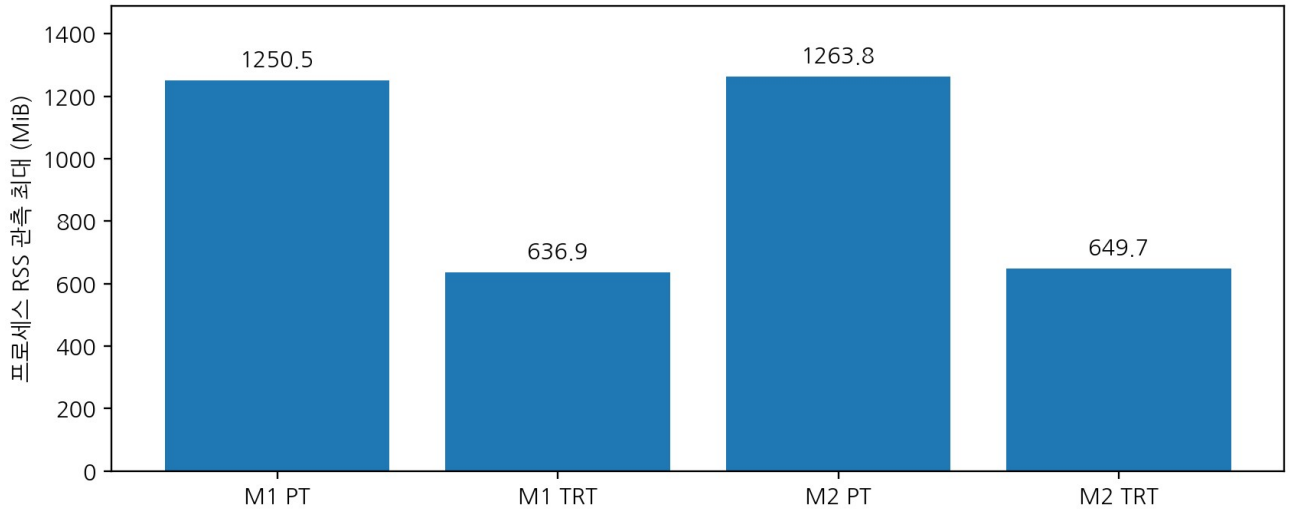


그림 1. 본 측정 구간의 프로세스 RSS 관측 최대. 백엔드별 3 회 중 최댓값이며 100ms 간격으로 수집했다.

M1 은 1,250.5→636.9MiB 로 49.1%, M2 는 1,263.8→649.7MiB 로 48.6% 감소했다. 기준 대비 RSS 최대 증가량도 M1 620.0→301.9MiB, M2 629.1→314.6MiB 로 낮아졌다. 단독 모델 실행에서 확인한 구체적인 자원 효율 성과다.

메모리 지표의 기준

RSS 는 라이브러리와 입력 이미지를 포함한 측정 프로세스의 메모리다. 기준값은 동일 72 장과 각 백엔드 라이브러리를 준비한 뒤 모델 구성 전에 기록했다. 따라서 감소율은 GPU 전용 메모리나 모델 파일 크기 대신 프로세스 RSS 에 적용한다.

RSS 는 /proc/self/status, 시스템 사용량 추정은 MemTotal−MemAvailable 로 수집했다. 범위가 겹쳐 합산하지 않으며, 로드·예열·측정 단계별 기록은 memory_summary.csv 에서 확인할 수 있다.

> 100ms 샘플링의 관측 최대값을 사용했다. 샘플이 없는 짧은 단계는 미관측으로 표시했고 GPU 전용 메모리는 별도 측정하지 않았다.

근거: [B06] memory_raw.csv, memory_summary.csv; [B02] memory; [B13] baseline 차감 및 최대값 재계산.

05 약 30ms 의 모델별 처리 시간과 속도 비교

원본 PT 와 TensorRT 의 전처리·후처리 포함 처리 시간을 비교했다. 조건당 3 회·1,080 구간의 전체 결과다. 단위: ms, image/s.

조건	평균	p50	p95	최소 / 최대	처리량
M1 PT	29.313	29.201	30.301	28.088 / 32.221	34.06
M1 TRT	29.022	29.310	30.537	22.725 / 31.700	34.41
M2 PT	29.480	29.529	30.042	28.566 / 30.412	33.87
M2 TRT	30.266	30.415	30.683	26.053 / 31.445	33.00

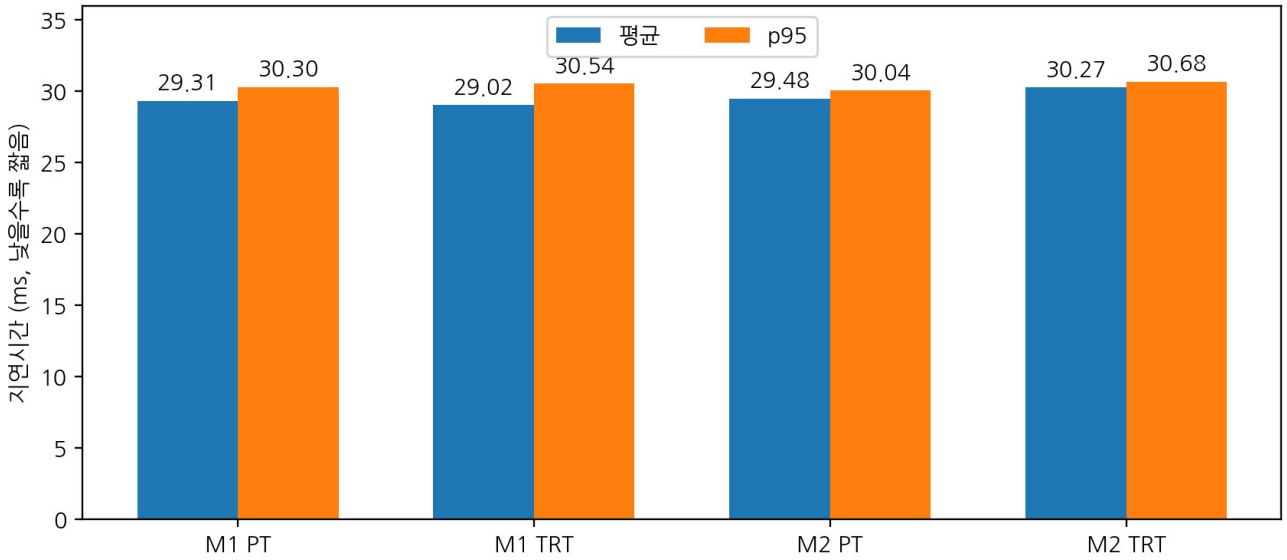


그림 2. 전체 지연시간 비교. y 축은 0 부터 표시했으며, p95 는 전체 1,080 구간의 95 백분위수다.

속도와 메모리를 함께 본 해석

M1 평균 지연은 29.313→29.022ms 로 0.291ms(0.99%) 줄었고 처리량은 34.41 image/s 였다. p50 은 29.201→29.310ms, p95 는 30.301→30.537ms 로 증가해 일관된 지연 개선으로 해석하지 않았다.

M2 평균 지연은 29.480→30.266ms 로 0.786ms(2.67%) 늘었고 처리량은 33.00 image/s 였다. 따라서 이번 적용의 주된 이점은 큰 속도 향상보다는 약 49%의 프로세스 RSS 감소와 근접한 검출 지표다.

측정 구간과 다음 개선 지점

처리량은 저장 사진을 각 모델에 개별 입력한 결과다. 실제 라인의 처리량은 자세 정렬·세 프레임 판정·DB·PLC 를 포함하는 통합 시험에서 별도로 확인한다.

> 속도 차이의 원인을 좁히기 위한 다음 단계는 전처리·GPU·전송·후처리별 프로파일링이다. 현재는 GPU 커널 단독시간을 측정하지 않아 특정 단계의 병목을 확정하지 않았다.

근거: [B05] latency_raw.csv, latency_summary.csv; 각 remote_results/results/<run_id>/run.json. [B13] 전체 구간 재집계 결과.

06 반복 실행과 초기화 시간 기록

실행 순서를 교차한 12 회 결과와 모델 로드·첫 호출 시간을 함께 보존했다.

실행 ID	평균 ms	p95 ms	image/s	로드 ms	첫 호출 ms
M1_PT_r1	29.473	30.621	33.88	1042.3	50.7
M1_TRT_r1	29.496	30.729	33.86	157.6	81.7
M2_PT_r1	29.810	30.180	33.50	1053.9	46.9
M2_TRT_r1	30.221	30.669	33.05	175.7	83.1
M1_TRT_r2	28.935	30.369	34.51	156.4	79.5
M1_PT_r2	29.074	29.743	34.35	1022.8	48.3
M2_TRT_r2	30.412	30.649	32.85	182.9	84.8
M2_PT_r2	29.038	29.438	34.39	1037.6	50.5
M1_PT_r3	29.393	30.389	33.97	1027.2	50.8
M1_TRT_r3	28.635	30.314	34.87	160.9	80.3
M2_PT_r3	29.591	29.983	33.75	1080.8	47.4
M2_TRT_r3	30.165	30.706	33.11	174.2	82.0

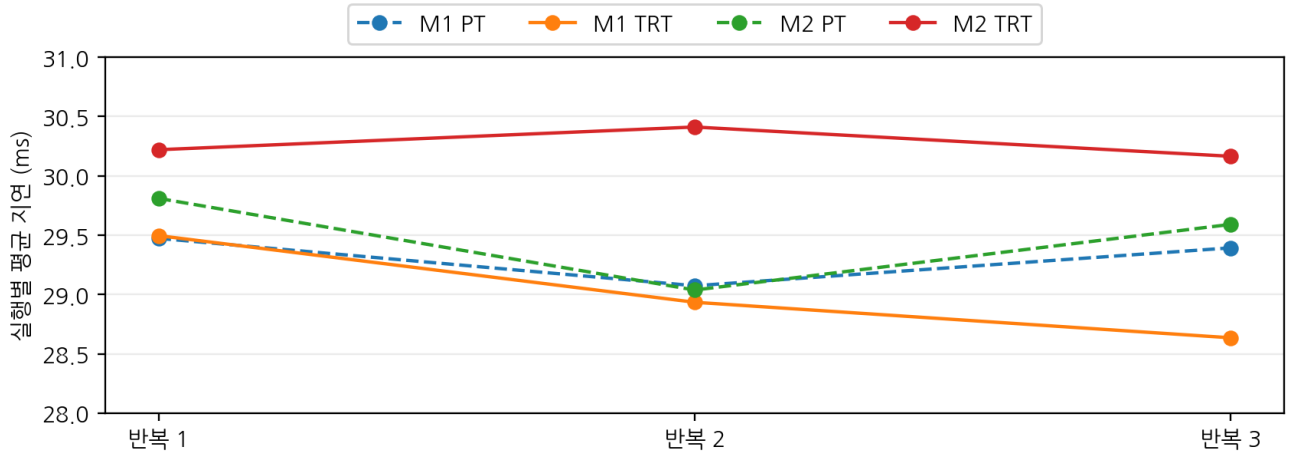


그림 3. 반복별 평균 지연시간. 차이를 읽기 위해 y 축을 28~31ms 로 확대했다. 전체 크기 비교는 그림 2 를 참조한다.

조건별 새 프로세스 3 회를 실행해 일회성 결과뿐 아니라 반복 편차도 확인했다. M1 TensorRT 평균은 29.496→28.935→28.635ms 였고 PT 에도 변동이 있었다. 조건당 1,080 구간은 동일 72 장의 반복 측정이다.

TensorRT 는 기록된 모델 로드 구간이 더 짧고 첫 호출 구간은 더 길었다. 정상상태 처리와 초기화 비용을 분리해 비교할 수 있도록 두 값을 모두 남겼다. 이는 백엔드 초기화 범위의 지표이며 앱 전체 기동시간과는 다르다.

근거: [B05] latency_summary.csv; [B02] measurement.order, warmup_calls, iterations. 통계적 유의성 검정과 최악 지연시간 보증은 수행하지 않았다.

07 최적화 전후 고정 조건 검출 결과

E03 72 장 전체에서 PT·TensorRT 의 고정 조건 TP·FP·FN 이 일치했고 mAP 도 근접했다.

구분	고정 조건 P/R	mAP 비교
confidence cutoff	0.25 (코드 비교 연산 >)	0.001 (코드 비교 연산 >)
공통 후처리	class-aware NMS IoU 0.45; max_det 300; 단일 argmax 클래스	왼쪽과 동일. 단, 면적 0 후보 보존의 평가 전용 연결 사용 (12 쪽).
정답 매칭 IoU	0.50	0.50 부터 0.95 까지 0.05 간격
집계	실제 TP/FP/FN 에서 P/R 계산	Ultralytics 8.4.118 ap_per_class

조건	TP/FP/FN	P@0.25	R@0.25	mAP50	mAP50-95
M1 PT	192/0/0	1.000	1.000	0.995000	0.639911
M1 TRT	192/0/0	1.000	1.000	0.995000	0.640873
M2 PT	72/0/0	1.000	1.000	0.995000	0.836717
M2 TRT	72/0/0	1.000	1.000	0.995000	0.836629

confidence 0.25·정답 IoU 0.50 에서 M1 은 192 개, M2 는 72 개 정답 박스를 양쪽 모두 검출했고 FP·FN 은 0 이었다. 네 조건의 전체 예측 288 기록을 보존해 이미지별 결과를 추적할 수 있다. 평가 단위는 E03 사진의 박스 검출이다.

클래스별 결과

조건	클래스	정답	TP/FP/FN	AP50-95
M1 PT	gray_pipe	96	96/0/0	0.722679
M1 PT	exhaust_top	48	48/0/0	0.548666
M1 PT	symbol_module	48	48/0/0	0.648386
M1 TRT	gray_pipe	96	96/0/0	0.722676
M1 TRT	exhaust_top	48	48/0/0	0.551515
M1 TRT	symbol_module	48	48/0/0	0.648429
M2 PT	product_envelope	72	72/0/0	0.836717
M2 TRT	product_envelope	72	72/0/0	0.836629

mAP50-95 변화는 M1 +0.0963%p, M2 −0.0088%p 로 작았다. 고정 조건의 검출 건수 유지와 함께 변환 후 검출 지표가 원본에 근접했음을 보여준다. 이 비교는 개발 검증의 관측값이며 통계적 동등성 시험과는 구분한다.

근거: [B07] accuracy_summary.csv, accuracy_by_class.csv, 각 r1/accuracy.json 및 predictions.json. [B02] accuracy. [B13] 저장 예측의 IoU 0.50 대응·합계 재확인.

08 출력 일관성과 정밀도 개선 지점

동일 입력에 대한 실행 방식 간 일관성을 확인하고, 정답 경계와의 차이도 함께 분석했다.

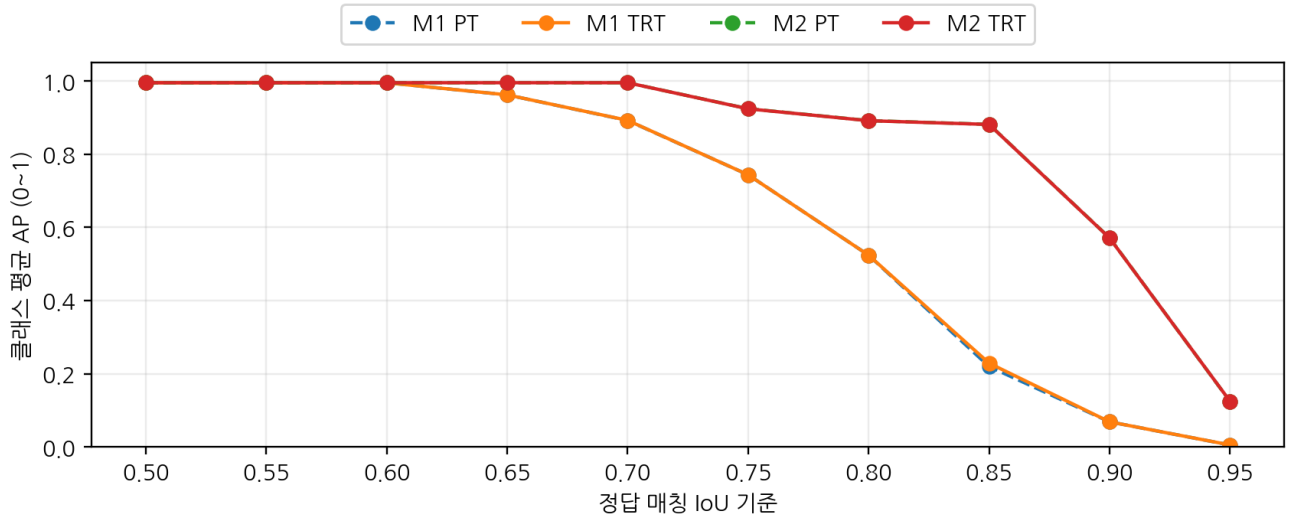


그림 4. 정답 매칭 IoU 별 클래스 평균 AP. 기존 accuracy.json 의 ap_by_iou 배열을 평균해 그렸다. 두 백엔드 곡선이 가까워 일부 선은 겹친다.

PT·TensorRT 의 IoU 별 AP 곡선이 근접했다. 두 백엔드 모두 엄격한 위치 기준에서 배기 부품 AP50-95 가 상대적으로 낮아, 후속 정밀도 개선의 우선 대상도 공통으로 확인했다(PT 0.548666, TRT 0.551515).

PT 대 TensorRT 저장 예측 비교: confidence 0.25

비교 지표	M1	M2
사진-모델 비교 수	72 쌍	72 쌍
대응되지 않은 예측	PT 0 / TRT 0	PT 0 / TRT 0
대응 박스 간 최소 IoU	0.998935	0.965331
최대 좌표 차이	0.0603 px	7.4605 px
최대 confidence 절댓값 차이	0.001611	0.000590
입력 텐서 SHA 대응	72 쌍 일치	72 쌍 일치

위 값은 prediction_comparison.csv 의 72 행씩을 집계한 결과다. 박스 좌표 차이는 원본 1280×720 좌표계의 대응 박스 모서리 차이이며, 정답과의 오차를 직접 뜻하지 않는다. 다음 두 쪽에서 정답과 두 실행 결과를 나란히 확인할 수 있다.

> 확인한 성과: 72 장 전체에서 박스 수·클래스 대응이 유지됐다. 좌표·confidence 차이는 위 표에 정량화했으며, 정답 경계에 대한 위치 정밀도는 AP 와 별도 사례로 평가했다.

근거: [B07] r1/accuracy.json 의 ap_by_iou; [B10] prediction_comparison.csv. [B13] 두 모델별 전체 행의 최소·최대·합계 집계.

09 실제 예측 비교 사례: M1

정상·결품의 정답과 두 백엔드 예측을 같은 이미지 ID 로 연결해 비교했다.

사례 A. D147 / 정상

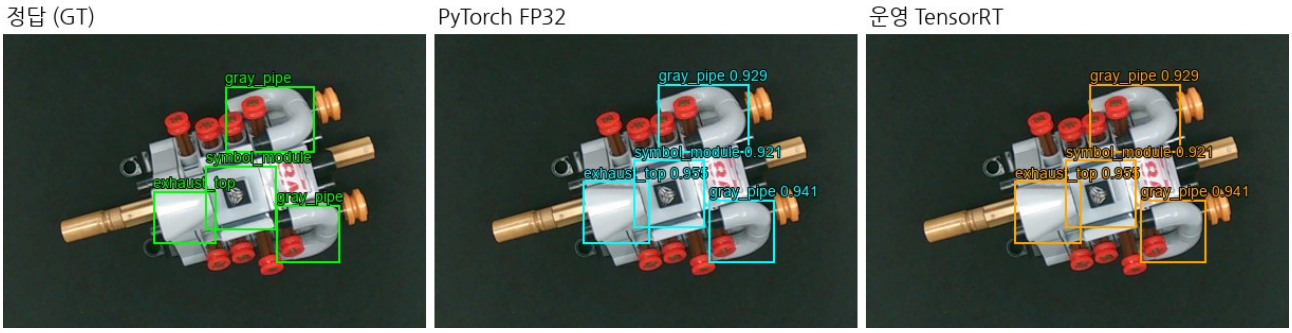


그림 5. 정상 D147 의 정답·PyTorch·TensorRT. 원본 증빙의 같은 엔진 영역을 확대했다.

정상 상태의 파이프 2 개·배기 1 개·문양 1 개를 PT·TensorRT 가 모두 검출했다. 실행 방식 간 최대 좌표 차이는 0.0506px, 최소 대응 IoU 는 0.999292 로 이 사례의 높은 출력 일관성을 확인했다.

사례 B. D195 / 문양 부품 결품



그림 6. D195 는 촬영 기록상 문양 부품 결품이다. 남아 있는 세 부품 박스와 결품 자리의 검출 유무를 비교한다.

문양 부품이 빠진 D195 에서 양쪽 모두 남은 세 부품을 검출하고, 없는 문양 부품을 추가 검출하지 않았다. M1 전체 비교 중 최대 좌표 차이가 가장 큰 사례에서도 차이는 0.0603px 였다(confidence 0.25).

자료	ZIP 내 확인 위치
원본·정답·예측	examples/M1/D147/ 및 examples/M1/D195/
정량 비교	prediction_comparison.csv 의 해당 model·image_id 행
전체 E03 예측	remote_results/results/M1_PT_r1/predictions.json remote_results/results/M1_TRT_r1/predictions.json

근거: [B10] examples.csv, examples/M1/{D147,D195}/ 및 prediction_comparison.csv. 그림 5-6 의 확대 범위는 보고서 작업용 figure_provenance.json 에 기록했다.

10 실제 예측 비교 사례: M2 와 전체 결품

엔진 전체와 부품 존재를 분리한 역할이 정상·결품 사진에서 어떻게 나타나는지 확인한다.

사례 C. D160 / 엔진 전체 박스의 좌표 차이

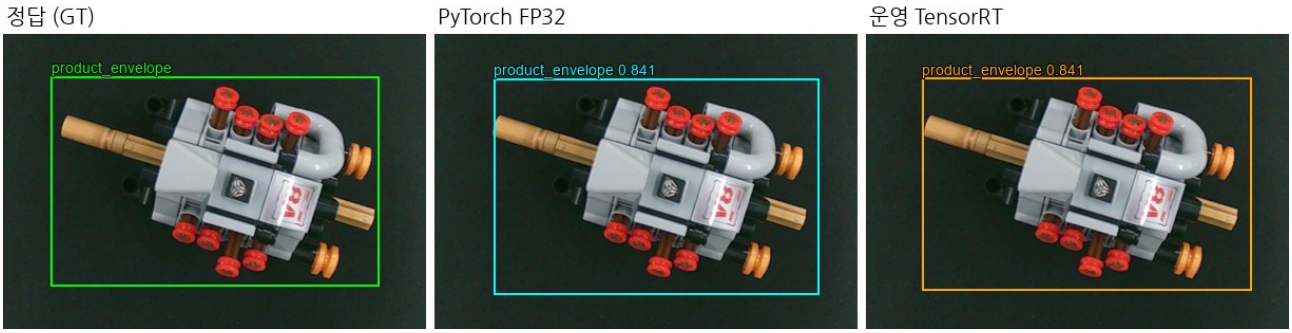


그림 7. D160 의 엔진 전체 정답과 PT·TensorRT 예측. 두 백엔드 모두 전체 엔진을 검출했다.

M2 의 최대 좌표 차이 사례 D160 에서도 양쪽 모두 정답 IoU 0.50 기준 TP 였다. 백엔드 간 최대 좌표 차이는 7.4605px, 대응 박스 IoU 는 0.965331 이며 엔진 전체 1 박스 검출은 유지됐다.

사례 D. D205 / 대상 부품 전체 결품

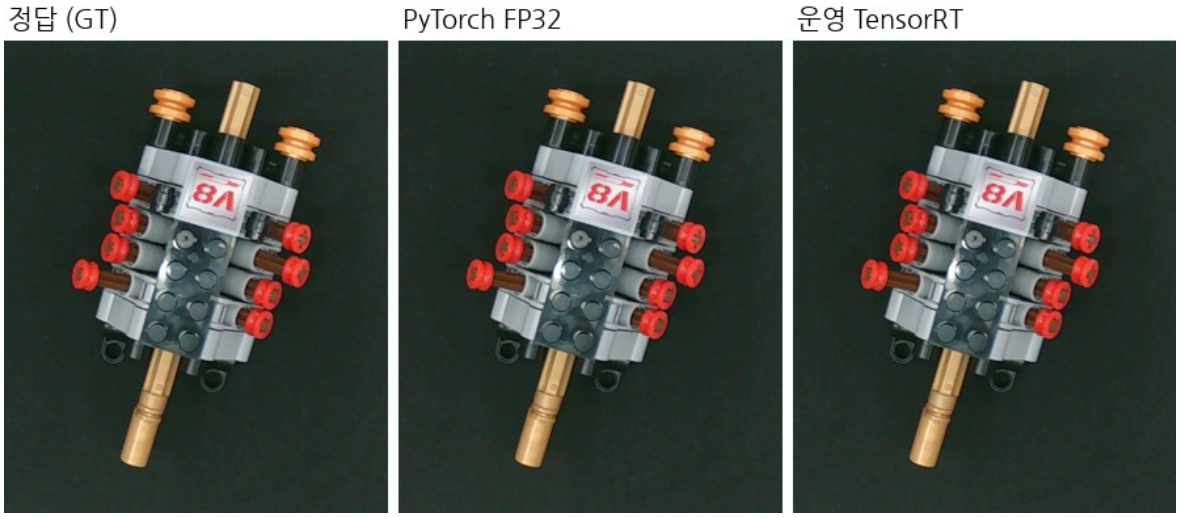


그림 8. D205 의 M1 정답과 두 실행 결과. 대상 부품이 모두 없으므로 세 패널 모두 M1 부품 박스가 없다.

대상 부품이 모두 빠진 D205 에서 M1 은 PT·TensorRT 모두 0 박스로 정답과 일치했다. 같은 사진의 M2 는 두 백엔드 모두 남아 있는 엔진 몸체를 1 박스로 검출했다. 부품 부재와 엔진 영역 존재를 별도로 표현하는 구조를 보여준다.

증빙에는 정상·결품과 출력 차이를 보여주는 13 개 모델-이미지 사례가 포함돼 있다. 모든 정량 지표는 대표 그림이 아닌 E03 전체 72 장으로 집계했다. 빈 벨트·자세·제품 단위 성능은 별도 통합 평가 범위다.

근거: [B10] examples/M2/D160/, examples/M1/D205/; [B07] M2 PT/TRT r1/predictions.json 의 D205; [B04] ground_truth.json. 전체 13 개 사례 위치는 examples.csv 에 연결돼 있다.

11 측정 신뢰성 확보와 평가 경로 보완

측정 중 발견한 환경·평가 연결 문제를 분리하고, 고정 사례 점검 후 전체 비교를 완료했다.

구분	발생 사실	처리 및 증빙
실행 전 환경	NumPy 2.2.6 과 설치 PyTorch 의 배열 변환 호환 문제	기존 NumPy 1.26.4 overlay 재사용. 설치·업그레이드 없음. 초기 사전검증 기록 보존.
attempt001	M1 PT/TRT 실행 후 M2 PT 의 낮은 cutoff 평가에서 degenerate restored box 오류	M2 PT 의 GPU 추론·360 회 시간 측정은 끝난 상태였다. 전체 순차 비교를 중단하고 3 회·1,080 구간 원본 보존.
평가 전용 보완	confidence 0.001 의 후보가 원본 범위로 clip 된 후 면적 0 이 될 수 있음	평가 전용 사본은 해당 후보를 삭제하지 않고 IoU 0 의 FP 후보로 남김. PT 와 TRT 에 같은 코드 적용.
attempt002	변경 프로토콜 고정 후 4 조건×3 회를 모두 재실행	운영 cutoff 0.25 시간 경로 및 운영 코드는 그대로. 본 보고서의 전체 결과는 두 번째 12 회에서 집계.

저임계값 평가 연결의 처리 범위

낮은 cutoff native 거부가 기록된 사진-조건	M1 PT	M1 TRT	M2 PT	M2 TRT
사진 수	0	0	72	72

confidence 0.25 의 본 측정 12 회는 모두 정상 종료했다. 표의 144 건은 mAP 용 confidence 0.001 에서 native 후처리가 입력을 거부한 진단 횟수다. 평가용 보완을 양쪽에 동일 적용했으며 현장 검사 ERROR 횟수와 구분한다.

평가 연결의 고정 사례 점검

보존된 adapter_tests.json 에는 CPU 고정 사례 10 개 통과 기록이 있다. 정답 일치, 빈 예측, 중복 예측, 잘못된 클래스, 정답 없음, 완전 예측의 AP, letterbox·역변환, class-aware NMS, padding 영역 면적 0 후보 유지, 정상 박스의 native/평가 사본 일치를 포함한다.

> mAP 는 면적 0 후보를 IoU 0 의 FP 후보로 보존한 평가용 경로를 사용했다. 운영 코드·confidence 0.25 의 측정 경로는 유지했다. 최종 4,320 구간은 보완 후 전체 재실행 결과이며 최초 중단 시도는 별도 보존했다.

근거: [B09] attempt001/, first_suite_failure.json, protocol_revisions/, low_cutoff_native_rejections.json; [B02] accuracy.zero_area_policy; [B12] code/test_adapter.py 및 adapter_tests.json.

12 운영본 보존과 서비스 복귀 확인

측정 전후의 파일 동일성과 서비스·새 영상·IPC 신호를 관측 기록으로 확인했다.

확인 단계	원자료에 기록된 내용
측정 전	서비스 active, PLC 운전 OFF·요청 LOW, 기존 engine-integrated-32c484ac6aeb07f1 확인.
일시 정지·측정	승인 후 운영 서비스를 정지하고 순차 측정. PLC START/STOP 명령 전송, 운영 파일 교체, 재부팅은 하지 않음.
최초 복구 문제	서비스는 시작됐지만 CAMERA_FRAME_TIMEOUT 발생. 사용자에게 같은 포트로 USB 재연결을 요청.
USB 재연결 후	새 카메라 프레임과 IPC HEALTH ready=True 를 확인. 웹 ready=False 잔존은 Codex 기록에서 과거 표시로 구분.
두 번째 측정 종료	window_result.json: 17:38:07-17:43:11 KST, state=RESTORED_READY, suite·restore returncode=0.
최종 추가 관측	restore_observation_174722.json: service active, 새 프레임 연속 증가, 실제 IPC READY, 측정 프로세스 종료.
변경 여부	운영 릴리스·설정 해시와 모델 패키지·재사용 소스 19 파일의 전후 해시 일치 기록. 같은 boot ID·25W mode 1.

복귀 확인 항목과 후속 통합 확인

최종 기록에서 서비스 active, camera_ready=True, 새 프레임 연속 증가와 IPC ready=True 를 확인했다. inspection_service.ready=False 및 AREA_REFERENCE_INVALID / UNKNOWN 표시도 원자료에 남아 있어, 실제 신호 복귀와 화면 전체 정상화는 구분한다.

상태 조회 과정의 last_status_error 는 원문에 보존했다. 최종 suite·restore returncode=0 과 이후 추가 관측을 함께 제시해, 종료 결과와 조회 중 발생 이력을 추적할 수 있게 했다.

> 이번에 확인한 복귀 범위는 같은 운영본의 서비스 실행·영상 수신·IPC 준비 신호다. 실물 엔진 투입 후 AI 판정→LED→DB→다음 이송의 확인은 통합 테스트에서 수행할 항목으로 남긴다.

근거: [B11] remote_results/window_result.json, restore_observation_173405.json, restore_observation_174722.json, operating_after_verification.json. KST 시각은 원문의 UTC 에 9 시간을 더해 표시했다.

13 구현 성과와 다음 고도화 방향

학습 가중치를 실제 Jetson 운영 파일과 연결하고, 자원 효율·검출 성능·처리 시간을 실측 근거로 제시했다.

확인한 성과	실측 근거와 의미
실행 메모리 효율	프로세스 RSS 관측 최대 M1 49.1%, M2 48.6% 감소. 라이브러리·입력까지 포함한 실행 프로세스의 자원 효율을 확인했다.
고정 조건 검출 결과 유지	E03 72 장, confidence 0.25·정답 IoU 0.50 에서 PT·TRT 모두 M1 TP192/FP0/FN0, M2 TP72/FP0/FN0 이었다.
실제 장치 처리 성능 확인	전처리·후처리 포함 TensorRT 평균 M1 29.022ms, M2 30.266ms. 큰 가속 효과보다는 약 30ms 처리와 메모리 절감이 이번 결과다.
반복 가능한 비교 근거	4 조건×3 회, 4,320 개 시간 기록과 전체 예측을 보존했다. 측정 조건·실행 순서·재시도 이력을 연결했다.
학습부터 운영까지 추적	PT→ONNX→TensorRT→운영 파일 해시를 연결하고, 운영 릴리스·설정 및 19 개 파일의 전후 동일성을 확인했다.

적용 범위

E03 개발 검증 72 장과 모델별 단독 호출이 대상이다. M1 은 사용자 승인 라벨, M2 는 AI 검토 라벨을 사용했다. 독립 최종시험·빈 벨트·다양한 현장 조건·제품 단위 판정은 후속 검증 범위다.

전처리·후처리 포함 지연과 100ms RSS 샘플을 기존 25W·동적 클록 조건에서 측정했다. GPU 커널 단독시간·전용 GPU 메모리·통계적 동등성·최악 지연 보증은 포함하지 않는다. 속도 결과는 M1 −0.99%, M2 +2.67%이며 p95 개선도 관측되지 않았다.

다음 고도화 계획

후속 목적	수행할 작업
속도 개선 지점 확인	전처리·GPU·전송·후처리를 나누어 프로파일링한 뒤, 실제 비용이 큰 단계부터 개선한다.
현장 통합 동작 검증	실물 정상·결품 투입, LED·이력·검사 ID 연결과 반복·현장변수 시험을 수행한다.
일반화 범위 확장	개발 검증과 분리된 시험 조건을 정하고, 빈 벨트·복합 결품·가림 등 현재 범위 밖의 입력을 추가 검증한다.

근거: [B01] README_KO.md 3-8 절; [B02-B11] 각 원문. 후속 항목은 보고서의 제안이며 실제 수행 결과가 아니다.

부록 A 모델 식별과 자료 무결성

모델·입력·프로토콜·원본 결과를 식별할 수 있도록 해시와 검증 범위를 보존했다.

모델 파일	SHA-256 (줄바꿈 없이 연결한 64 자리)
M1 PT	42db183006ad2a4f61dc9c22e7a61a5b 506cdacb5099004fc7c3b73b74bf5259
M1 ONNX	433b16fd1e802bdf2cb0afba6bb6487a 839d94b5adc286185b93fd3953b9c296
M1 TRT	743ce54b4d5c7b8a36addf3dbff50fa6 93ec4a509b31b476f68efc69f1bf2d6c
M2 PT	cf117defe782e1ae8b355e0ed13c014f c6f1538aa2dcdbe0fb6cfa54200f7755
M2 ONNX	5cb024bb911f9357e46c12c3d2a7e4b5 f19af20e5692013037c9235e0deca830
M2 TRT	c82f2658ac20d06985a647c15e551c68 1e394451cfa1c53baed64f639bcebf83

프로토콜 SHA-256
e9d3d6b317d224afb7083dfb5185269824bfe0a62c42e531cd80d33edad41236

원본 Benchmark ZIP SHA-256
06321e2cb49302744181615e126d4f2d62b20e4d2c2782e8b2a29f815876cf29

문서 작성 단계에서 재확인한 항목

검증 대상	결과와 범위
ZIP 및 파일 목록	37,112,177 바이트, 608 파일. ZIP SHA·CRC 확인; manifest 의 607 파일 크기·SHA 및 자기 자신을 포함한 전체 파일집합 일치.
원격 수집 사본	보존된 원격 해시 기록 233 개와 업로드된 로컬 사본의 크기·SHA 일치. 장치 재접속 검증은 아님.
시간·메모리	4,320 개 시간의 시작/끝 차이, 반복 순서·횟수, 전체/반복별 요약, 메모리 단계별 최대·기준 차감 계산 일치.
정답·예측	144 개 라벨과 pixel JSON 대응; 네 조건의 저장 예측을 IoU 0.50 으로 대조해 TP/FP/FN 재확인. 입력 텐서 SHA 144 쌍 일치.
mAP·예시	보존된 AP 배열·클래스표·평균 계산을 대조. mAP 평가기 자체를 재실행한 것은 아님. 예시 13 개 참조·원본 해시 확인.

> 검증 파일: 이번 측정·복구의 기준은 원본 Benchmark ZIP 내부 verification.json(999 바이트)이다. 이전 자산 조사 검증과 구분해 제출 묶음에 별도 보존했다.

근거: [B08] model_hashes.json; [B02] protocol.json; [B12] bundle_manifest.json, verification.json, ZIP 옆 무결성 JSON; [B13] reviewer_audit.json. 모델 바이너리를 이 문서 작성 환경에서 재실행하지 않았다.

부록 B 평가 근거 찾아보기와 재현 안내

본문의 [Bxx]는 아래 원자료 위치를 가리킨다. 경로는 원본 Benchmark ZIP 의 루트 기준이다.

ID	자료 위치 / 확인 내용
R0	통합 프로젝트 평가표 1 쪽 영역 5: ONNX·TensorRT 변환과 동일 조건 FPS·Latency·메모리·정확도 비교.
B01	README_KO.md / Codex 가 작성한 원본 요약과 적용 범위
B02	protocol.json / 입력·모델·실행 순서·시간·메모리·정확도 조건, 고정 코드 해시
B03	environment.json, environment_effective.json, telemetry_raw.jsonl, telemetry_summary.json
B04	input_manifest.csv, ground_truth.json, ground_truth/M1/ 및 M2/ / E03 72 장과 모델별 정답
B05	latency_raw.csv, latency_summary.csv; remote_results/results/<run_id>/{run.json,latency_raw.csv}
B06	memory_raw.csv, memory_summary.csv; 각 실행의 telemetry.jsonl / 단계별 메모리·온도 원문
B07	accuracy_summary.csv, accuracy_by_class.csv; remote_results/results/<모델>_<PT|TRT>_r1/{accuracy,predictions}.json
B08	provenance/M1/ 및 M2/; model_hashes.json, model_hash_verification.json / 변환·운영본 연결
B09	attempt001/, first_suite_failure.json, protocol_revisions/, low_cutoff_native_rejections.json / 실패와 보완
B10	examples.csv, examples/, prediction_comparison.csv / 13 개 모델-이미지 사례와 전체 144 쌍 비교
B11	remote_results/window_result.json, restore_observation_174722.json, operating_after_verification.json
B12	code/, source_snapshot/, adapter_tests.json, collected_evidence_verification.json, verification.json, bundle_manifest.json
B13	본 보고서 제출 묶음의 reviewer_audit.json / 업로드된 기록의 로컬 재집계·무결성 점검

다른 자료와 함께 제출할 때

이 보고서 PDF 와 M1_M2_benchmark_evidence_v001.zip 을 함께 제공한다. 실제 학습·검증 사진 전체는 앞서 작성한 M1_M2_dataset_evidence_v002 에 있고, 이 Benchmark ZIP 에는 모든 입력·해시·정답·예측 및 대표 원본을 연결했다. 모델 바이너리와 전체 학습 데이터를 중복 포함하지 않았다.

재실행의 전제

원본 모델·E03 파일을 해시로 준비하고 새 측정 폴더의 경로·프로토콜을 먼저 고정한다. 기존 호환 환경과 CPU 연결 테스트를 확인한 후, 실제 STOP·유휴 및 운영 영향 승인을 전제로 서비스 창을 사용한다. 완료·실패 어느 경우든 같은 서비스를 복구하고 새 영상·IPC 를 다시 확인한다. 원래 결과 폴더를 덮어쓰거나 과거 절대경로 명령을 무검토로 실행하지 않는다.

문서 작성 범위: 첨부 자료를 읽고 저장된 수치·예측·파일을 대조하여 표와 그림을 작성했다. 새 GPU 추론·현장 시험·모델 변경은 수행하지 않았다. 원본 수치와 최초 실패 이력은 수정하지 않았다.